

Self-Supervised Multi-Channel Hypergraph Convolutional Network for Social Recommendation

• ABSTRACT

- 在推荐系统中，当用户项交互数据稀疏时，通常使用社会关系来提高推荐质量。大多数现有的社会推荐模型利用成对关系挖掘潜在的用户偏好。然而，现实生活中用户之间的交互非常复杂，用户关系可能是高阶的。**超图提供了一种自然的方法来模拟复杂的高阶关系，但它在改善社会推荐方面的潜力还没有得到充分的探索。在本文中，我们填补了这一空白，并提出了一种多通道超图卷积网络，通过利用高阶用户关系来增强社会推荐。**从技术上讲，网络中的每个通道都编码了一个超图，该超图通过超图卷积描述了一个常见的高阶用户关系模式。通过聚合通过多个渠道学习的嵌入，我们获得了全面的用户表示来生成推荐结果。然而，聚合操作也可能掩盖不同类型的高阶连接信息的固有特征。为了弥补聚合损失，我们创新地将自监督学习集成到超图卷积网络的训练中，以通过分层互信息最大化来重新获得连接信息。在多个真实世界数据集上的实验结果表明，所提出的模型优于 SOTA 方法，消融研究验证了多通道设置和自监督任务的有效性。我们的模型的实现可通过 <https://github.com/Coder-Yu/RecQ> 获得。

• INTRODUCTION

- 在过去的十年中，社交媒体的繁荣极大地改变了人们的思维方式和行为方式。研究表明，人们可能会改变自己的态度和行为，以响应他们认为朋友可能会做或想的事情，这就是所谓的**社会影响力**。同时，也有研究表明，人们倾向于与与自己有相似偏好的人建立联系，这就是所谓的**同质性**。基于这些发现，**社会关系通常被集成到推荐系统中以缓解数据稀疏问题。通常，在社交推荐系统中，如果用户与项目的交互很少，系统将依靠她朋友的交互来推断她的偏好并生成更好的推荐。**基于这种范式，已经开发出大量的社交推荐模型，并且与一般推荐模型相比表现出更强的性能。
- 最近，图神经网络（GNN）在广泛的领域取得了巨大的成功。由于其强大的关系数据建模能力，基于 GNN 的模型在社交推荐方面也表现出突出的表现。然而，这些**基于 GNN 的社交推荐模型的一个关键限制是它们仅利用简单的成对用户关系，而忽略了用户之间普遍存在的高阶关系**。虽然关系的长期依赖关系（即友谊的传递性）也被认为是高阶的，可以通过使用 k 个图神经层来合并来自 k -hop 社会邻居的特征来捕获，但是这些基于 GNN 的模型无法制定和捕获超越成对关系的复杂高阶用户关系模式（如图 1 所示）。例如，很自然地认为，两个有社交联系并购买相同物品的用户比仅社交联系的用户具有更强的关系，而在以前的社交推荐模型中，前者的共同购买信息往往被忽略。
- 超图概括了边缘的概念，使其连接两个以上的节点，为用户之间复杂的高阶关系建模提供了一种自然的方式。尽管在用户建模方面比简单图有很大的优势，但超图的优势在社交推荐中的探索不足。在本文中，我们通过研究融合超图建模和图卷积网络的潜力来填补这一空白，并提出了一种多通道超图卷积网络（MHCN），通过利用高阶用户关系来增强社交推荐。从技术上讲，我们通过统一形成特定三角关系的节点来构建超图，这些节点是一组精心设计的具有潜在语义的三角形图案的实例（如图 2 所示）。当我们在社交推荐系统中定义多个类别的主题时，这些主题具体化了不同类型的高阶关系，例如“有一个共同的朋友”、“购买相同物品的朋友”和“购买相同物品的陌生人”，每个渠道的所提出的

超图卷积网络承担了编码不同主题诱导的超图的任务。通过聚合通过多个渠道学习到的多个用户嵌入，我们可以获得全面的用户表示，这些表示被认为包含多种类型的高阶关系信息，并且很有可能通过项目嵌入产生更好的推荐结果。

- 然而，尽管多通道设置有好处，但聚合操作也可能掩盖不同类型的高阶连接信息的固有特征，因为不同的通道将学习不同超图上不同分布的嵌入。为了解决这个问题并充分继承超图中的丰富信息，我们创新地将自监督任务集成到多通道超图卷积网络的训练中。与现有的对图进行扰动以增强真实性的研究不同，我们建议通过利用超图结构来构建自我监督信号，直觉是综合用户表示应该反映用户节点的局部和全局高阶连接模式在不同的超图中。具体来说，我们利用超图结构中的层次结构，并在层次上最大化用户表示、以用户为中心的子超图和全局超图之间的互信息。这里的互信息衡量了子超图和整个超图的结构信息量，通过减少局部和全局结构的不确定性来推断用户特征。最后，我们将推荐任务和自我监督任务统一在一个主辅助学习框架下。通过联合优化这两个任务并利用所有组件的相互作用，推荐任务的性能取得了显着的提升。
- 本文的主要贡献总结如下：
 - 我们通过在多渠道设置下利用多种类型的高阶用户关系来研究在社交推荐中融合超图建模和图神经网络的潜力。
 - 我们创新地将自监督学习融入到超图卷积网络的训练中，并表明自监督辅助任务可以显着改善社交推荐任务。
 - 我们对多个真实世界的数据集进行了广泛的实验，以证明所提出模型的优越性，并彻底消融模型以通过消融研究调查每个组件的有效性。

• PROPOSED MODEL

- Preliminaries(预备知识)
 - 令 $U = \{u_1, u_2, \dots, u_m\}$ 表示用户集 ($|U| = m$)， $I = \{i_1, i_2, \dots, i_n\}$ 表示项目 ($|I| = n$)。 $I(u)$ 是用户消费的集合，其中包含用户 u 消费的项目。 $R \in R^{m \times n}$ 是一个存储用户-项目交互的二进制矩阵。对于每一对 (u, i) ， $r_{ui} = 1$ 表示用户 u 消费了项目 i ，而 $r_{ui} = 0$ 表示项目 i 未暴露给用户 u ，或者用户 u 对项目 i 不感兴趣。在本文中，我们关注top-K推荐， r^{\wedge} 表示项目 i 被推荐给用户 u 的概率。至于社会关系，我们使用 $S \in R^{m \times m}$ 来表示非对称的关系矩阵，因为我们在有向社交网络上工作。在我们的模型中，我们有多层卷积层，我们使用 $\{P(1), P(2), \dots, P(l)\} \in R^{m \times d}$ 和 $\{Q(1), Q(2), \dots, Q(l)\} \in R^{n \times d}$ 分别表示在每一层学习到的大小为 d 的用户和项目嵌入。在本文中，我们使用粗体大写字母表示矩阵，使用粗体小写字母表示向量。
 - 定义1：让 $G = (V, E)$ 表示一个超图，其中 V 是包含 N 个唯一顶点的顶点集， E 是包含 M 个超边的边集。每个超边 $e \in E$ 可以包含任意数量的顶点并被分配一个正权重 w_{ee} ，所有的权重都形成一个对角矩阵 $W \in R^{M \times M}$ 。超图可以用关联矩阵 $H \in R^{N \times M}$ 表示，其中 $H_{ie} = 1$ 如果超边 $e \in E$ 包含顶点 $v_i \in V$ ，否则为 0。顶点和边度矩阵是对角矩阵，分别用 D 和 L 表示，其中 $D = \square \square W H$; $L = \square \square H$ 。需要注意的是，在本文中， w_{ee} 被统一分配为 1，因此 W 是单位矩阵。
- Multi-Channel Hypergraph Convolutional Network for Social Recommendation(用于社交推荐的多通道超图卷积网络)

- 在本节中，我们将介绍我们的模型 MHCN，它代表多通道超图卷积网络。在图 3 中，说明了我们模型的示意图。
- Hypergraph Construction. (超图构造)
 - 为了制定用户之间的高阶信息，我们首先在社交推荐系统中对齐社交网络和用户-项目交互图，然后在这个异构网络上构建超图。与通过统一给定类型的实体来构造超边的先前模型不同，我们的模型根据图结构构造超边。由于社交网络中的关系通常是定向的，因此社交网络的连接可以是各种类型的。在本文中，我们使用一组精心设计的主题来描述社交网络中常见的三角形结构类型，从而指导超图的构建。
 - Motif作为涉及多个节点的特定局部结构，在[26]中首次引入。它已被广泛用于描述各种网络中的复杂结构。在本文中，我们只关注三角形图案，因为社交网络中普遍存在三元闭合，但我们的模型可以无缝扩展以处理更复杂的图案。图 2 显示了所有使用的三角形图案。据透露，M1-M7 对社交计算至关重要，我们进一步设计 M8-M10 以涉及用户-项目交互以进行补充。给定主题 M1 - M10，我们根据底层语义将它们分为三组。M1 - M7 总结了显式社交网络中所有可能的三角关系，并描述了高阶社交连接，如“有一个共同的朋友”。我们将此组命名为“社会主题”。M8 - M9 表示复合关系，即“朋友购买同一物品”。这种类型的关系可以看作是加强联系的信号，我们将 M8-M9 命名为“联合基序”。最后，我们还应该考虑没有明确社交关系的用户。因此，M10 是非封闭的，它定义了没有社交联系但购买相同物品的用户的隐含高阶社交关系。我们将 M10 命名为“购买主题”。在这三种主题的规则下，我们可以构造三个包含不同高阶用户关系模式的超图。我们使用关联矩阵 H_s 、 H_j 和 H_p 分别表示这三个基序诱导的超图，其中这些矩阵的每一列表示一个超边。例如，在图 3 中， $\{u1, u2, u3\}$ 是 M4 的一个实例，我们使用 $e1$ 来表示这个超边。然后，根据定义 1，我们有 $H_s u1, e1 = H_s = H_s = 1$
- Multi-Channel Hypergraph Convolution (多通道超图卷积)
 - 在本文中，我们使用三渠道设置，包括“社交渠道 (s)”、“联合渠道 (j)”和“购买渠道 (p)”，以响应三种类型的三角形图案，但可以调整通道数量以适应更复杂的情况。每个通道负责编码一种类型的高阶用户关系模式。由于不同的模式可能对最终推荐性能表现出不同的重要性，因此将完整的基本用户嵌入 $P(0)$ 直接提供给所有通道是不明智的。为了控制从基本用户嵌入 $P(0)$ 到每个通道的信息流，我们设计了一个带有自门控单元 (SGU) 的预过滤器，其定义为：(1) 其中 $W_{gc} \in R^{d \times d}$, $b_{gc} \in R^d$ 是要学习的参数， $c \in \{s, j, p\}$ 表示通道， \odot 表示元素级乘积， σ 是 sigmoid 非线性。自门控机制有效地用作乘法跳跃连接，它学习非线性门以通过维度重新加权以特征粒度调制基本用户嵌入，然后我们获得特定于通道的用户嵌入 $P_c(0)$ 。
 - 参考[10]中提出的谱超图卷积，我们将超图卷积定义为：(2) 不同之处在于我们遵循 [6, 14] 中的建议来移除线性变换的可学习矩阵和非线性激活函数（例如leaky ReLU）。通过用 H_s 、 H_j 和 H_p 中的任何一个替换 H_c ，我们可以利用超图卷积网络的优势来学习用户表示在相应通道中编码的高阶信息。由于 D_c 和 L_c 是仅重新缩放嵌入的对角矩阵，我们在下面的讨论中跳过它们。超图卷积可以看作是对超图结构执行“节点-超边-节点”特征转换的两阶段细化。乘法运算 $H \top P(l)$ 定义了从节点传递到超边的消息，然后预乘 H_c 被视为聚合从超边到节点的信息。然

而，尽管有超图卷积的好处，但仍有大量的主题诱导的超边（例如，在使用的数据集 LastFM 中有 19,385 个社交三角形），这将导致构建关联矩阵 H_c 的成本很高。但是由于我们只利用三角形图案，我们表明可以通过利用矩阵乘法的关联属性以灵活有效的方式解决这个问题。

- 根据[60]，我们令 $B = S \odot ST$ 和 $U = S - B$ 分别是双向和单向社交网络的邻接矩阵。我们使用 AM_k 来表示基序诱导的邻接矩阵，并且 $(AM_k)_{i,j} = 1$ 表示顶点 i 和顶点 j 出现在 M_k 的一个实例中。由于两个顶点可以出现在 M_k 的多个实例中，因此 $(AM_k)_{i,j}$ 的计算公式为： (3)
- Learning Comprehensive User Representations （学习全面的用户表示）
 - 在通过 L 层传播用户嵌入之后，我们平均在每一层获得的嵌入以形成最终的特定于通道的用户表示： $P^* = \frac{1}{L} \sum_{l=1}^L P(l)$ 以避免过度平滑问题。